

Transfer Learning dengan Convolutional Neural Network untuk Deteksi Penyakit Gastrointestinal

Kurniawan Khaikal¹, Rizky Umar Faruq Ely²

Informatika, Fakultas Teknik

Universitas Muhammadiyah Malang

krnhl29@gmail.com, rizkyumr@gmail.com

ABSTRAK

Klasifikasi patologi yang otomatis dan akurat pada gambar endoskopi merupakan tantangan saat ini untuk Gastroenterologi. Makalah ini menyajikan pendekatan untuk membantu proses diagnosis medis penyakit dan anomali pada saluran pencernaan berdasarkan klasifikasi fitur yang diekstraksi dari gambar endoskopi dengan jaringan saraf convolutional dan transfer learning type fine-tuning. Strategi yang diusulkan dievaluasi pada gambar endoskopi nyata dari dataset Kvasir. Secara khusus, penulis menggunakan 8000 gambar dari 8 kelas yang menunjukkan landmark anatomis, temuan patologis, dan prosedur endoskopi di saluran pencernaan. Metode yang diusulkan memungkinkan memperoleh klasifikasi akurasi 94.6%, yang 2.1% lebih akurat daripada hasil terbaik dalam literatur di bawah kondisi yang sangat mirip, dan hingga 13.6% lebih tepat.

Kata kunci : *Gastrointestinal, Transfer Learning, Convolutional Neural Network.*

Pendahuluan

Penyakit gastrointestinal (GI) adalah semua patologi di mana sistem pencernaan terpengaruh. Penyakit GI yang paling umum adalah polip, kanker, infeksi, kolitis ulserativa, diverticulitis dan lain-lain[1]. Menurut Organisasi Kesehatan Dunia, penyakit ini termasuk dalam sepuluh besar penyebab kematian pada manusia[2].

Saat ini, ada beberapa metode untuk mengeksplorasi penyakit pada saluran GI, yang utama adalah pencitraan diagnostik yang dievaluasi oleh dokter dan tes laboratorium. Namun, pelabelan penyakit mungkin sedikit berbeda antara profesional, dalam hal tingkat keparahan. Diagnosis yang tepat waktu dan akurat adalah awal dari perawatan yang benar. Untuk alasan ini, dalam makalah ini penulis membahas masalah klasifikasi gambar penyakit dan kelainan dalam saluran GI, menggunakan teknik pembelajaran transfer dengan CNN.

Penelitian ilmiah telah memberikan kontribusi besar di bidang kesehatan, misalnya, melalui pemrosesan gambar,

manajemen data besar, dan kecerdasan buatan[3]-[4].

Secara khusus, salah satu tugas medis dipelajari dalam keadaan seni, terdiri dari beberapa strategi CNN untuk mendeteksi, segmen dan mengklasifikasikan penyakit pada saluran pencernaan[5].

Namun ketika metode ini mengusulkan CNN yang baru dilatih dari awal, sejumlah besar data diperlukan, yang sulit diakses. ketika menggunakan transfer learning, jumlah gambar yang dibutuhkan lebih sedikit, tetapi akurasi masih bisa ditingkatkan. Misalnya pada[6], penulis mengusulkan untuk menggabungkan model CNN, seperti DenseNet-201, ResNet-18, dan VGG-16, untuk menghasilkan satu vektor fitur dalam lapisan pengelompokan rata-rata global (GAP). Metodenya mencapai presisi 97%, yang tertinggi sejauh yang diketahui. Namun, hasil seperti itu membutuhkan 400 epochs dan 10 jam pelatihan. Kemudian pada penelitian[7], telah diusulkan fitur penggabungan yang diekstraksi dari Gabor dan CNN, mencapai akurasi 92,1% hanya menggunakan satu dari

8 kelas yang tersedia di dataset Kvasir, dan bobot awal tidak dipelajari dari domain medis. Hingga akhirnya pada penelitian yang serupa[8], telah mencapai akurasi 91,5% menggunakan augmentasi data dan pembelajaran transfer dengan arsitektur Inception v3 selama 17 epochs.

Untuk alasan ini, pembelajaran transfer adalah teknik yang sangat mencolok untuk bidang kesehatan, karena memungkinkan penggunaan kembali informasi dari model terlatih sebelumnya dengan sejumlah besar gambar dari area lain yang lebih mudah diakses.

Untuk melakukan pekerjaan ini, penulis menggunakan real image yang diambil dalam prosedur endoskopi melalui gastroskopi dan kolonoskopi[9]. Secara khusus, penulis menggunakan dataset Kvasir [10] kumpulan dari 8,000 gambar yang sangat berguna di bidang penelitian dalam deteksi otomatis penyakit pada saluran pencernaan melalui teknik pembelajaran mesin dan sistem diagnostik berbantuan komputer (CAD).

Metode Penelitian

CNN berisi beberapa lapisan tersembunyi khusus, yang kekuatannya terletak pada pembelajaran lapisan representasi hierarki dan konsep yang sesuai dengan tingkat abstraksi yang berbeda. Jaringan ini paling efektif ketika mereka menggunakan kumpulan data besar untuk menghitung bobot yang secara intrinsik untuk menentukan operasi jaringan. Namun, di bidang medis, kumpulan data besar ini umumnya tidak tersedia, apalagi dengan labelnya masing-masing, karena ini adalah tugas yang berat. Untuk alasan ini, penulis mengeksplorasi transfer learning untuk mendeteksi anomali dan penyakit saluran pencernaan dalam gambar endoskopi menggunakan

VGG16 CNN yang sebelumnya dilatih dengan dataset ImageNet.

A. Persiapan Data

Untuk penelitian ini data akan dibagi menjadi 2 bagian untuk masing-masing kualitas gambar kedalam bagian train, validation dan test. Tujuannya adalah untuk mengevaluasi perilaku metode

Tabel I
Distribusi data

	Data 80			Data 70		
	%	Gambar per kelas	Total	%	Gambar per kelas	Total
Traian	80	800	6400	70	700	5600
Validasi	15	150	1200	25	250	2000
Test	5	50	400	5	50	400

B. Convolutional Neural Network

VGG16 adalah model saraf 16-lapisan, yang arsitekturnya dijelaskan pada Tabel II. Ini memiliki filter konvolusi yang sangat kecil dengan ukuran (3×3) dan Max-pooling (2×2) masing-masing tiga lapisan Conv2D. Ukuran input default untuk model ini adalah 224×224 dan semua lapisan benar-benar terhubung. Dalam konteks ini, dimensi tambahan memainkan peran penting, terutama ketika lesi sangat kecil dan mirip dengan jaringan di sekitarnya.

Tabel II
Lapisan VGG16

Layer			
1	Conv2D	3x3	64
2	Conv2D	3x3	64
MaxPooling			
3	Conv2D	3x3	128
4	Conv2D	3x3	128
MaxPolling			
5	Conv2D	3x3	256
6	Conv2D	3x3	256
7	Conv2D	3x3	256
MaxPooling			
8	Conv2D	3x3	512
9	Conv2D	3x3	512
10	Conv2D	3x3	512

	MaxPooling		
11	Conv2D	3x3	512
12	Conv2D	3x3	512
13	Conv2D	3x3	512
	MaxPooling		
14	Dense		
15	Dense		
16	Dense + Softmax		

C. Transfer Learning

Kemajuan teknologi untuk meningkatkan tingkat deteksi kelainan memerlukan kumpulan data gambar yang besar, namun pengumpulan dan anotasi gambar medis terbatas dalam banyak kasus karena proses akuisisi data seringkali rumit dan mahal. Kemudian, dengan adanya penyakit baru, tidak umum bagi dokter untuk memiliki banyak gambar berlabel yang dapat mereka klasifikasikan. Pelabelan database untuk penyakit apa pun adalah proses yang melibatkan waktu dan profesional khusus[11]. Oleh karena itu, teknik transfer learning dan model CNN sangat menguntungkan bidang kedokteran karena mampu menghasilkan representasi gambar endoskopi tingkat tinggi, yang dapat disimpulkan bahwa dari mode pre-training dengan dataset citra akan memungkinkan secara efisien mentransferkan ke tugas citra medis[12].

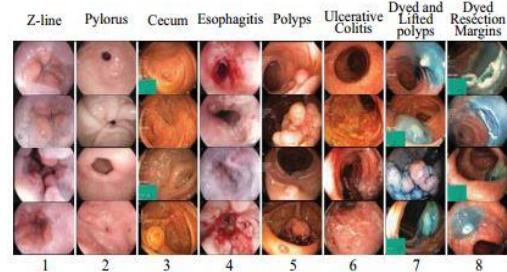
Simulasi dan Hasil

Makalah ini menggunakan dataset Kvasir, terdiri dari 8,000 gambar saluran cerna dibagi menjadi 8 kelas. Gambar 2 menunjukkan empat gambar yang dipilih secara acak dari masing-masing dari 8 kelas yang disusun secara vertikal, dengan nama masing-masing.

Kumpulan gambar diklasifikasikan menjadi tiga landmark anatomi penting dan tiga temuan klinis yang signifikan. Juga, ini berisi dua kelas gambar yang terkait dengan pengangkatan polip endoskopi. Secara total, ada 1,000 gambar untuk setiap kelas, setiap gambar dengan resolusi spasial yang


berbeda antara 720x576 dan 1920×1072 piksel.

Gambar 2.
Contoh Dataset Citra



Confusion matrix memberikan hasil klasifikasi dalam data validasi untuk delapan kelas yang dihasilkan oleh 80% dari dataset pelatihan, seperti yang ditunjukkan pada Gambar 3.

Gambar 3.
Confusion Matrix



Angka-angka di dalam kotak sesuai dengan jumlah gambar yang ditandai dengan kelas. Perhatikan bahwa matriks menunjukkan tren kesatuan. Artinya, nilai tertinggi terkonsentrasi pada diagonal utama, yang menunjukkan klasifikasi yang benar. Kemudian nilai di luar diagonal setara dengan sampel yang salah label.

Akhirnya, Tabel III menunjukkan ketepatan metode yang diusulkan dalam penelitian ini, dibandingkan dengan 3 pendekatan lain dalam literatur yang dipaparkan dalam pengantar penelitian ini.

Tabel III**Hasil Pelatihan Model**

Metode	ACC	REC	PRE	F1
CNN	0.915	0.915	0.915	0.915
Inception + Fine Tuning + Data Augmentasi				
Metode yang diusulkan	0.946	0.874	0.876	0.872

Secara khusus, dalam Metode yang Diusulkan (dengan Pendekatan 1) penulis memperoleh akurasi 94.6%.

Kesimpulan

Penelitian ini menyajikan pendekatan untuk mengklasifikasikan penyakit dan anomali saluran pencernaan dalam gambar endoskopik dari dataset publik Kvasir, mengalahkan akurasi metode alternatif yang canggih. Terutama, metode yang diusulkan didasarkan pada pembelajaran transfer melalui Penyetelan halus pada jaringan saraf konvolusi VGG16, yang sebelumnya dilatih dengan dataset ImageNet. Kombinasi teknik seperti augmentasi data dan penyesuaian hyperparameter, memungkinkan penulis untuk mengklasifikasikan dataset Kvasir ke dalam delapan kategori dengan akurasi tinggi 94,6%. Ini menunjukkan sekali lagi bahwa pembelajaran mesin dan transfer adalah alternatif yang menjanjikan untuk dukungan cepat dan akurat dari keputusan medis melalui diagnosis bantuan komputer.

Referensi

- [1] and R. E. S. Tehrani, M. Klinge, M. Saul, M. Morris, B. Diergaarde and Schoen, "Prevalence of colorectal cancer and advanced adenoma in patients with acute diverticulitis: implications for follow-up colonoscopy," vol. 91, 2020.
- [2] "The top 10 causes of death," WHO, 2020. [https://www.who.int/news-](https://www.who.int/news-room/fact-sheets/detail/the-top-10-causes-of-death)
- [3] E. Mojica, S. Pertuz, and H. Arguello, "High-resolution coded-aperture design for compressive X-ray tomography using low resolution detectors," *Opt. Commun.*, vol. 404, no. February, pp. 103–109, 2017, doi: 10.1016/j.optcom.2017.06.053.
- [4] V. L. Patel *et al.*, "The coming of age of artificial intelligence in medicine," *Artif. Intell. Med.*, vol. 46, no. 1, pp. 5–17, 2009, doi: 10.1016/j.artmed.2008.07.017.
- [5] H. Borgli *et al.*, "HyperKvasir, a comprehensive multi-class image and video dataset for gastrointestinal endoscopy," *Sci. Data*, vol. 7, no. 1, pp. 1–14, 2020, doi: 10.1038/s41597-020-00622-y.
- [6] C. Gamage, I. Wijesinghe, C. Chitraranjan, and I. Perera, "GI-Net: Anomalies Classification in Gastrointestinal Tract through Endoscopic Imagery with Deep Learning," *MERCon 2019 - Proceedings, 5th Int. Multidiscip. Moratuwa Eng. Res. Conf.*, pp. 66–71, 2019, doi: 10.1109/MERCon.2019.8818929.
- [7] N. Ghatwary, X. Ye, and M. Zolgharni, "Esophageal Abnormality Detection Using DenseNet Based Faster R-CNN with Gabor Features," *IEEE Access*, vol. 7, pp. 84374–84385, 2019, doi: 10.1109/ACCESS.2019.2925585.
- [8] A. Asperti and C. Mastronardo, "The effectiveness of data augmentation for detection of gastrointestinal diseases from endoscopical images," *BIOIMAGING 2018 - 5th Int. Conf. Bioimaging, Proceedings; Part 11th Int. Jt. Conf. Biomed. Eng. Syst. Technol. BIOSTEC 2018*, vol. 2, pp. 199–205, 2018, doi: 10.5220/0006730901990205.
- [9] S. J. Heller and J. L. Tokar, "Current status of advanced gastrointestinal endoscopy training fellowships in the united states," *Adv. Med. Educ. Pract.*,

vol. 2, pp. 25–34, 2011, doi:
10.2147/AMEP.S13310.

- [10] K. Pogorelov *et al.*, “Efficient disease detection in gastrointestinal videos – global features versus neural networks,” *Multimed. Tools Appl.*, vol. 76, no. 21, pp. 22493–22525, 2017, doi: 10.1007/s11042-017-4989-y.
- [11] Z. Jiang, H. Zhang, Y. Wang, and S. B. Ko, “Retinal blood vessel segmentation using fully convolutional network with transfer learning,” *Comput. Med. Imaging Graph.*, vol. 68, no. April, pp. 1–15, 2018, doi: 10.1016/j.compmedimag.2018.04.005.
- [12] A. Van Opbroek, M. A. Ikram, M. W. Vernooij, and M. De Bruijne, “Transfer learning improves supervised image segmentation across imaging protocols,” *IEEE Trans. Med. Imaging*, vol. 34, no. 5, pp. 1018–1030, 2015, doi: 10.1109/TMI.2014.2366792.